



Человек руководит лабораторией, агенты в ней работают

Агенты работали часами без участия человека, но направление, роли и приоритеты задавал человек



Цикл одного исследования ветка — отдельная копия кода; ревью — независимая проверка кода другой моделью



Как прошли исследования

Каждая строка — одно исследование, каждый значок — один шаг: какая модель работала и чем закончилось

 Gemini 3.8 Flash — исследователь	 Claude Opus 5.5 — инженер	 GPT-6.1 Sol — ревьюер	 работа принята
R1, R4. Среда и гипотезы	        	7 ошибок найдено, два вывода перевёрнуты	
K1–K4. Обзоры литературы	     	проверка нашла две выдуманные ссылки	
R13. Миссия, заданная словами	    	модель — миссия 6 из 6, правило — 0 из 6	
R3 → R16. Цена ожидания модели	    →  	ждать — минус 73 очка; ехать, пока думает: +42	
R10. Смена грунта на пути	    	выигрыш не показан — так и записано	
G2. Потеря положения в Gazebo	   	возврат на базу в Gazebo: 8 из 9 → 7 из 7	
P1. Где робот теряет очки	   	переживает сбой датчика: +6,4 очка	
A1. Новые схемы агента	   	не лучше нынешней; потолок — 92,5 очка	
R14. Самокалибровка датчика	 	ревью вернуло работу; отложена	
F2. SLAM вместо готовой карты	   	совпадение с готовой картой 96–99%; правки идут	

Вывод. Качество держится на устройстве процесса — отдельная ветка, независимое ревью, пересчёт чисел, — а не на вере в один ответ модели.