



Человек руководит лабораторией, агенты в ней работают

Агенты работали часами без участия человека, но направление, роли и приоритеты задавал человек



Цикл одного исследования ветка — отдельная копия кода; ревью — независимая проверка кода другой моделью



Как прошли исследования

Каждая строка — одно исследование, каждый значок — один шаг: какая модель работала и чем закончилось

 Gemini 3.8 Flash — исследователь	 Claude Opus 5.5 — инженер	 GPT-6.1 Sol — ревьюер	 работа принята							
R1, R4. Среда и гипотезы										7 ошибок найдено, два вывода перевёрнуты
K1–K4. Обзоры литературы										проверка нашла две выдуманные ссылки
R13. Миссия, заданная словами										модель — миссия 6 из 6, правило — 0 из 6
R3 → R16. Цена ожидания модели					→					ждать — минус 73 очка; ехать, пока думает: +42
R10. Смена грунта на пути										выигрыш не показан — так и записано
G2. Потеря положения в Gazebo										возврат на базу в Gazebo: 8 из 9 → 7 из 7
P1. Где робот теряет очки										переживает сбой датчика: +6,4 очка
A1. Новые схемы агента										не лучше нынешней; потолок — 92,5 очка
R14. Самокалибровка датчика										ревью вернуло работу; отложена
F2. SLAM вместо готовой карты										карта робота совпала с готовой на 96–99%

Вывод. Качество держится на устройстве процесса — отдельная ветка, независимое ревью, пересчёт чисел, — а не на вере в один ответ модели.