



Человек руководит лабораторией, агенты в ней работают

Агенты работали часами без участия человека, но направление, роли и приоритеты задавал человек



Цикл одного исследования ветка — отдельная копия кода; ревью — независимая проверка кода другой моделью



Как прошли исследования

Каждая строка — одно исследование, каждый значок — один шаг: какая модель работала и чем закончилось

 Gemini 3.8 Flash — исследователь  Claude Opus 5.5 — инженер  GPT-6.1 Sol — ревьюер  работа принята

R1, R4. Среда и гипотезы											7 ошибок найдено, два вывода перевёрнуты
K1–K4. Обзоры литературы											проверка нашла две выдуманные ссылки
R13. Миссия, заданная словами											модель — миссия 6 из 6, правило — 0 из 6
R3 → R16. Цена ожидания модели					→						ждать — минус 73 очка; ехать, пока думает: +42
R10. Смена грунта на пути											выигрыш не показан — так и записано
G2. Потеря положения в Gazebo											возврат на базу в Gazebo: 8 из 9 → 7 из 7
P1. Где робот теряет очки											переживает сбой датчика: +6,4 очка
A1. Новые схемы агента											не лучше нынешней; потолок — 92,5 очка
M1. Два робота с координацией											прогон короче на 26 с, заряда на четверть меньше
R14. Самокалибровка датчика											ревью вернуло работу; отложена
F2. SLAM вместо готовой карты											карта робота совпала с готовой на 96–99%

Вывод. Качество держится на устройстве процесса — отдельная ветка, независимое ревью, пересчёт чисел, — а не на вере в один ответ модели.