



Человек руководит лабораторией, агенты в ней работают

Агенты работали часами без участия человека, но направление, роли и приоритеты задавал человек



Цикл одного исследования ветка — отдельная копия кода; ревью — независимая проверка кода другой моделью



Как прошли исследования

Каждая строка — одно исследование, каждый значок — один шаг: какая модель работала и чем закончилось

 Gemini 3.8 Flash — исследователь	 Claude Opus 5.5 — инженер	 GPT-6.1 Sol — ревьюер	 работа принята								
R1, R4. Среда и гипотезы										7 ошибок найдено, два вывода перевёрнуты	
K1–K4. Обзоры литературы										проверка нашла две выдуманные ссылки	
R13 → L3. Миссия словами						→					модель — 45–46 из 48 прогонов, правило — 0 из 48
R16. Ехать, пока модель думает							→				на настоящей модели: стоять 34,7 → ехать 73,2 очка
R10. Смена грунта на пути											выигрыш не показан — так и записано
G2 → G3. Положение и сторожа					→						возврат на базу в Gazebo: 8 из 9 → 7 из 7
P1 → P2. Где робот теряет очки						→					сбой датчика: +6,4; пять правок: не показано
A1. Новые схемы агента											не лучше нынешней; с подсказками — 92,5 очка
R12. Выбор опыта с учётом цены											расход на расследование: 0,54 → 0,08
R14. Самокалибровка датчика											неверный закон датчика: 1% → 71% образцов
J1. Быстрая модель-сторож											миссия «ровно два образца»: 20 из 20
M1. Два робота с координацией											прогон короче на 26 с, заряда на четверть меньше
F2. SLAM вместо готовой карты											карта робота совпала с готовой на 96–99%

Вывод. Качество держится на устройстве процесса, а не на вере в один ответ модели.